



**IPB University**  
— Bogor Indonesia —

Divisi Matematika Komputasi  
Program Studi S1 Matematika  
Departemen Matematika

# **PREDIKSI JUMLAH *HOTSPOT* DI KALIMANTAN DENGAN METODE REGRESI PROSES GAUSSIAN BERDASARKAN INDIKATOR IKLIM**

Hari Nurdianto (G5401201089)

**Dosen Pembimbing 1**

Prof. Dr. Ir. Sri Nurdianti, M.Sc

**Dosen Pembimbing 2**

Mochamad Tito Julianto, M.Kom

**Moderator**

Dr. Ir. Retno Budiarti, M.S.





### **1. Pendahuluan**



### **4. Kesimpulan dan Saran**





### **2. Metode Penelitian**




### **5. Daftar Pustaka**

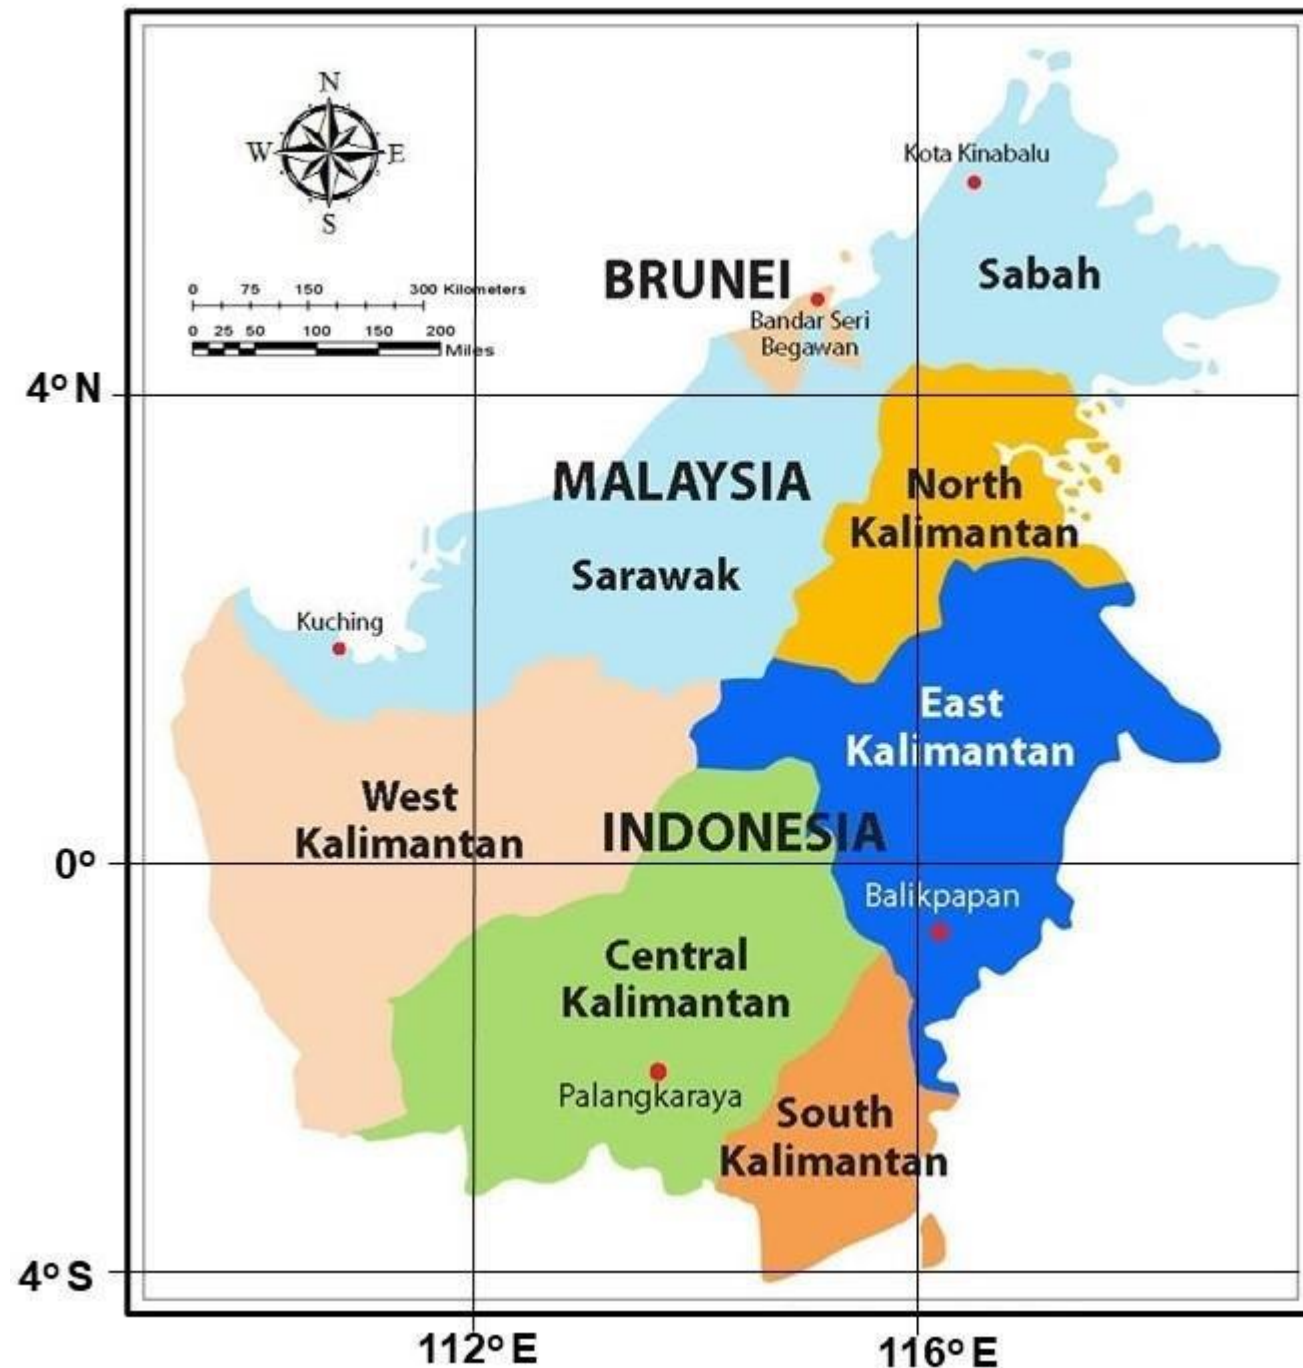


### **3. Hasil dan Pembahasan**



# PENDAHULUAN






Pulau **Kalimantan** merupakan salah satu pulau terluas **ketiga** di dunia.

Kalimantan merupakan salah satu wilayah di Indonesia yang sering mengalami permasalahan terkait **kebakaran hutan** (Saharjo 2023).

Indikasi kejadian kebakaran di Indonesia dapat diketahui dari informasi titik panas atau **hotspot**.

Sumber : BPS Kalimantan Timur 2020





Kebakaran hutan memiliki dampak negatif yang serius, baik terhadap lingkungan, ekonomi, maupun kesehatan manusia.



Bagaimana caranya mencegah kebakaran hutan?



Salah satu caranya dengan memprediksi jumlah *hotspot*!



Bagaimana cara memprediksi *hotspot*?



Salah satu caranya menggunakan metode prediksi model *machine learning*!

## PENELITIAN SEBELUMNYA

- Sebastian DM. 2023. Konstruksi model *Artificial Neural Network* untuk estimasi jumlah *hotspot* di Kalimantan berdasarkan indikator iklim [skripsi]. Bogor: Institut Pertanian Bogor
- Fallahi PAN. 2023. Model *machine learning* menggunakan metode regresi *random forest* dan *gradient boosting* pada data jumlah *hotspot* di Kalimantan [skripsi]. Bogor: Institut Pertanian Bogor



**Metode prediksi yang digunakan pada penelitian sebelumnya memiliki kendala pada pemilihan *hyperparameter* dalam memprediksi *hotspot*.**




**Dibutuhkan model *low hyperparameter complexity* dengan tingkat akurasi yang tinggi.**

1. Mengonstruksi model regresi proses Gaussian untuk memodelkan jumlah *hotspot* di wilayah Kalimantan menggunakan indikator iklim dengan melakukan pemilihan kernel yang paling cocok untuk model serta melakukan *tuning* pada *hyperparameter*.
2. Membandingkan nilai akurasi dari metode optimisasi *Bayesian optimization*, *grid search*, dan *random search* untuk menentukan model dengan performa terbaik.



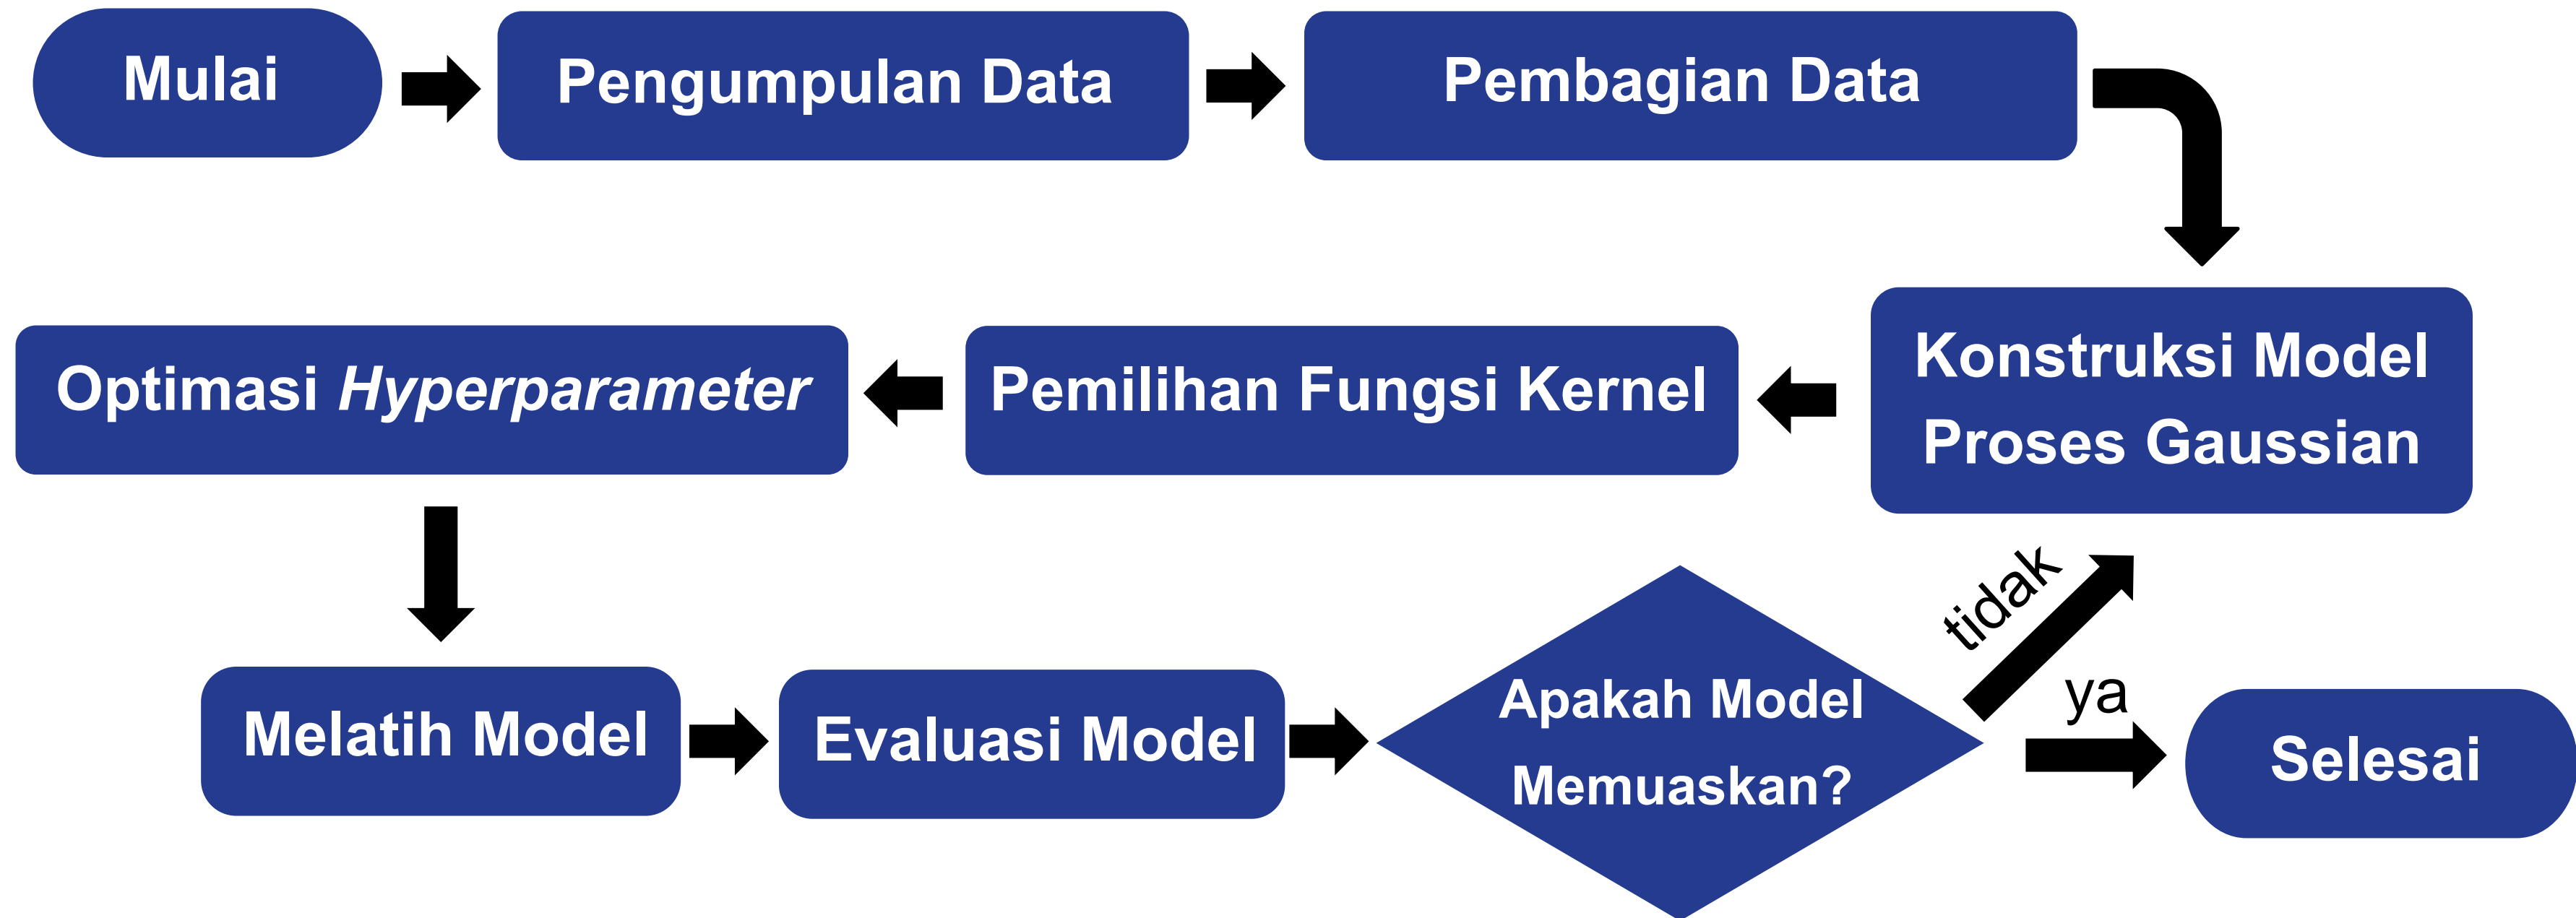


# METODE





## TAHAPAN PENELITIAN



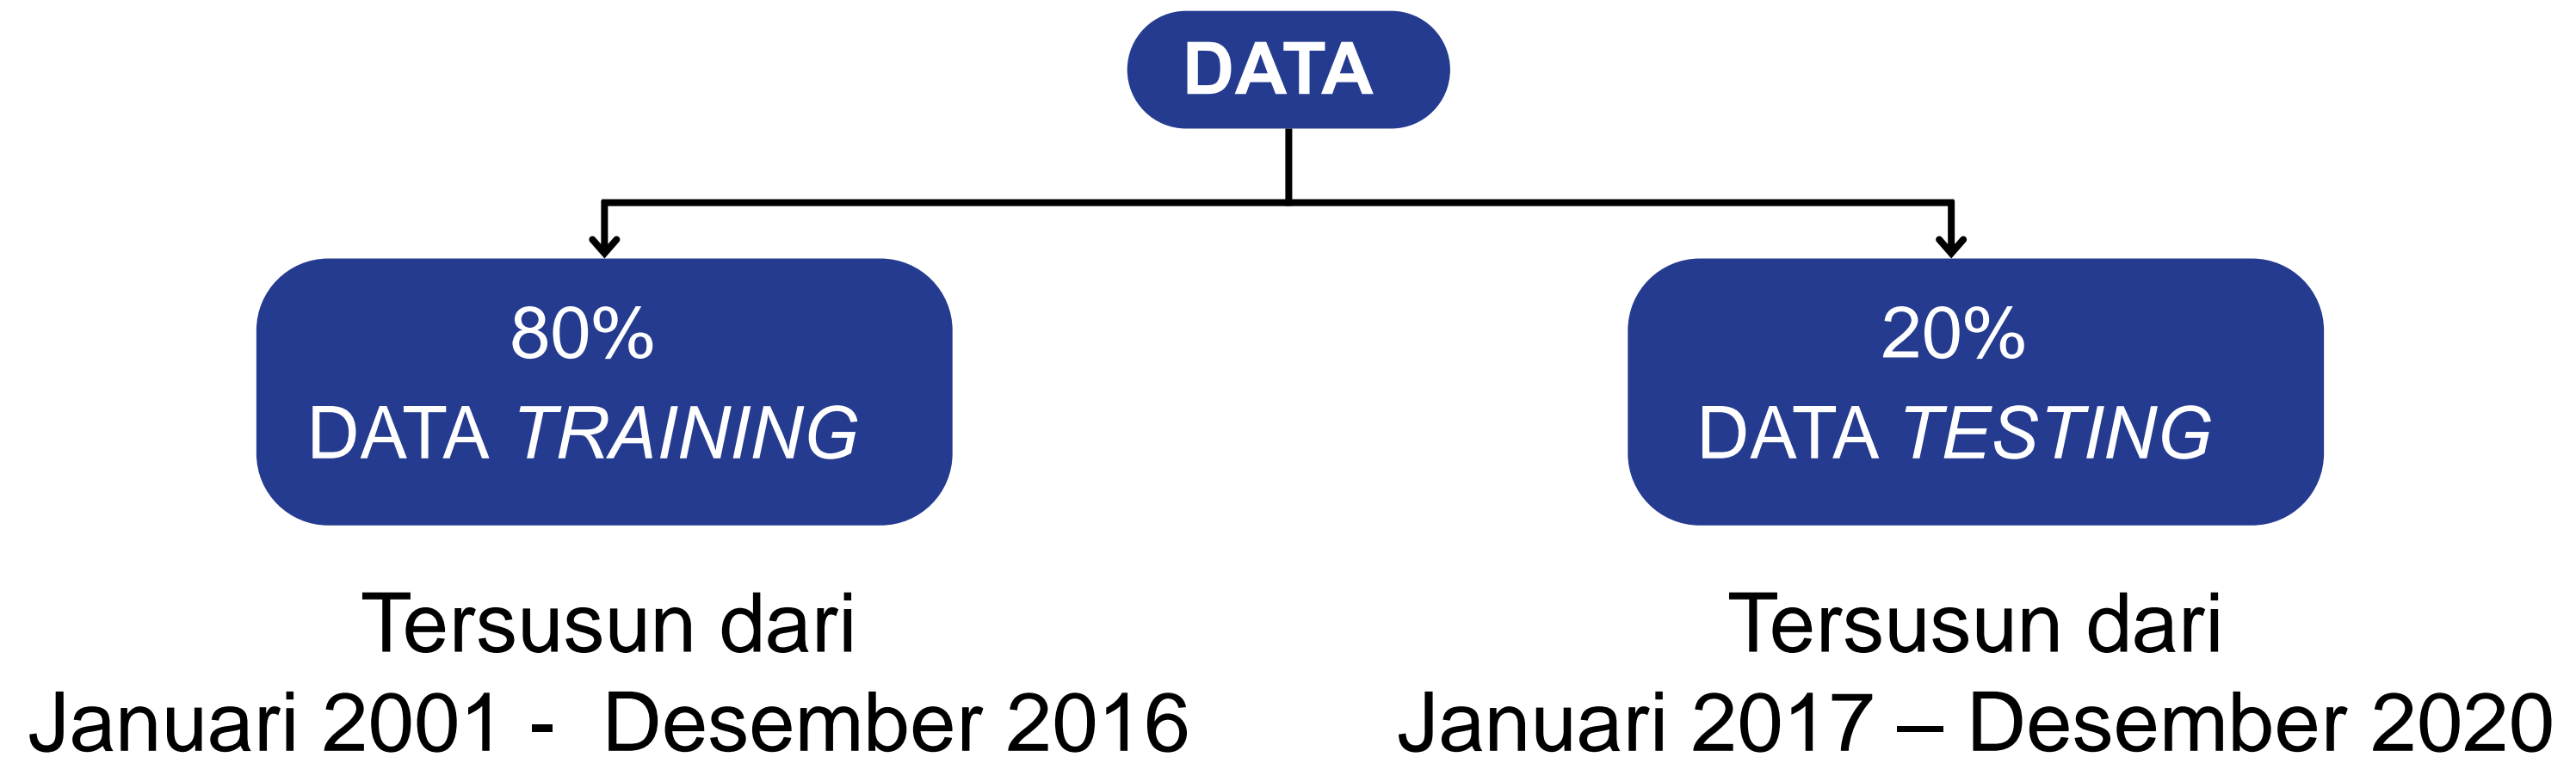
DATA



Data yang digunakan penelitian ini merupakan data temporal dari indikator iklim mulai Januari 2001 hingga Desember 2020. Data ini merupakan modifikasi dari data digunakan oleh Sebastian (2023) yang sebelumnya telah diekstraksi oleh Najib (2022).

Tabel 1. Peubah-peubah yang digunakan dalam penelitian


Peubah	Jenis Peubah	Keterangan
$x_1$	Penjelas	Rata-rata curah hujan
$x_2$	Penjelas	Rata-rata anomali curah hujan
$x_3$	Penjelas	Banyaknya hari tanpa hujan
$x_4$	Penjelas	Indeks ENSO
$x_5$	Penjelas	Indeks IOD
$y$	Respon	Jumlah <i>hotspot</i>

## PEMBAGIAN DATA





# REGRESI PROSES GAUSSIAN



# Regresi Proses Gaussian

Probabilistik



→ Estimasi ketidakpastian

Fleksibel

→ Data *input* baru tidak merubah model


Non-parametrik → Fleksibel dalam memodelkan data yang kompleks

Berasal dari konsep probabilistik







## Distribusi Normal



$$\mathcal{N}(\mu, \sigma) \quad f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

## Distribusi Normal Multivariat



$$\mathcal{N}(x|\mu, \Sigma) = \frac{1}{(2\pi)^{m/2} |\Sigma|^{1/2}} \exp \left[ -\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right]$$

# Dua Bentuk Pemodelan Dalam Regresi Proses Gaussian

## ***Weight Space View***

*Input* berupa kumpulan titik

***Weight Space View*** berfokus  
pada parameter bobot

## ***Function Space View***


*Input* berupa kumpulan fungsi

***Function Space View*** lebih umum  
digunakan dan lebih intuitif.

Pada dasarnya regresi proses Gaussian memandang model sebagai distribusi probabilistik atas fungsi-fungsi yang mungkin.

# Distribusi Normal Multivariat

## Dimensi tak hingga



Setiap variabel acak dimodelkan sebagai distribusi Gaussian



Jumlah variabel acak tak terbatas




MVN berdimensi tak terbatas

Apakah variabel acak saling berkorelasi satu sama lain?




# Vektor Acak Bebas



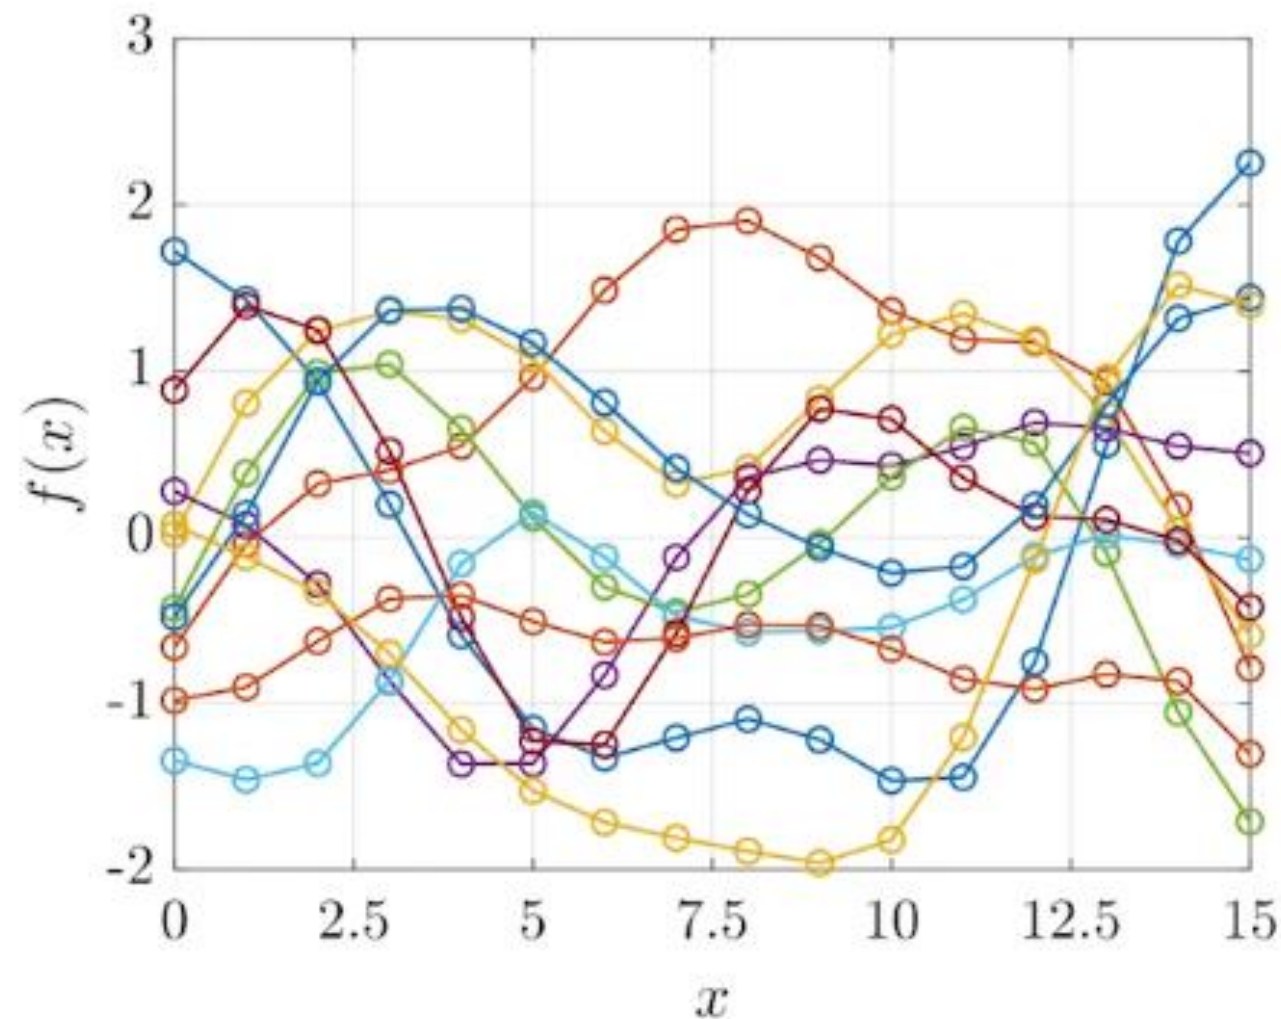
Vektor acak bebas

$$\Sigma =$$




Elemen-elemen diluar diagonal adalah nol

# Vektor Acak Berkorelasi



**Vektor acak berkorelasi**

$$\Sigma =$$



**Elemen-elemen diluar  
diagonal tidak nol**



## Prediksi dalam Regresi Proses Gaussian

Apabila variabel *error* mengikuti sebaran pada persamaan regresi

$$y = f(\mathbf{x}) + \varepsilon$$

maka sebaran bersamanya menjadi

$$\begin{bmatrix} \mathbf{f} \\ f^* \end{bmatrix} \bigg| \mathbf{X}, \boldsymbol{\theta} \sim \mathcal{N} \left( \mathbf{0}, \begin{bmatrix} \mathbf{K} & \mathbf{k} \\ \mathbf{k}^T & k \end{bmatrix} \right)$$



$$\begin{bmatrix} \mathbf{y} \\ y^* \end{bmatrix} \bigg| \mathbf{X}, \boldsymbol{\theta} \sim \mathcal{N} \left( \mathbf{0}, \begin{bmatrix} \mathbf{K} + \sigma^2 \mathbf{I} & \mathbf{k} \\ \mathbf{k}^T & k \end{bmatrix} \right)$$

(Rasmussen dan Williams 2006)

# Prediksi dalam Regresi Proses Gaussian

Sebaran marginal dari  $y^*$  adalah Gaussian

$$y^* | \mathbf{y}, \mathbf{X}, \boldsymbol{\theta} \sim \mathcal{N}(m(\mathbf{x}^*), V(\mathbf{x}^*))$$



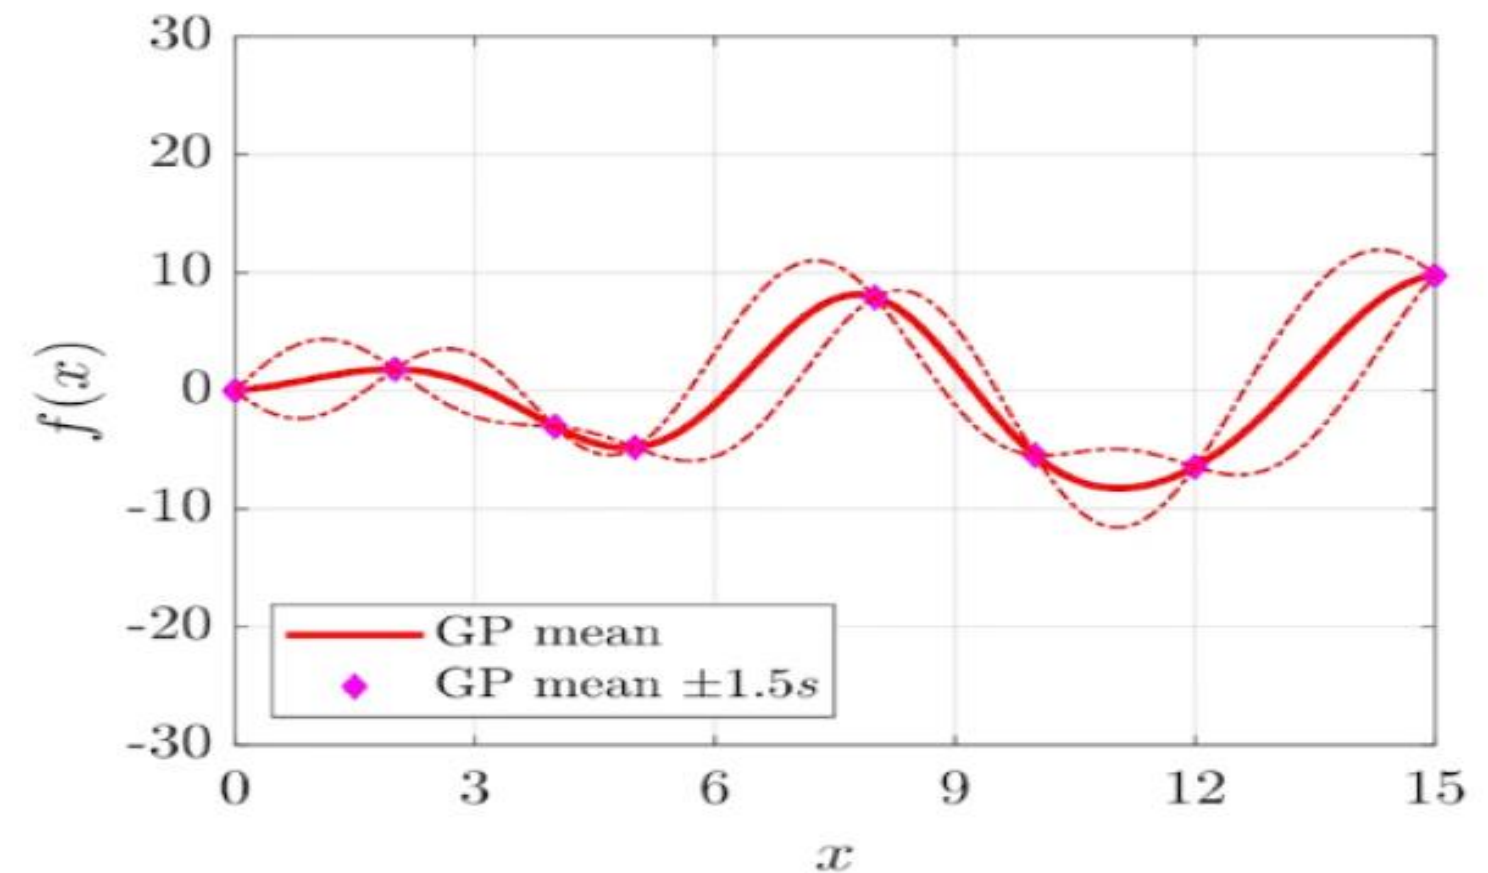
$$m(\mathbf{x}^*) = \mathbf{k}^T (\mathbf{K} + \sigma^2 \mathbf{I})^{-1} \mathbf{y}$$

➔ Rataan prediksi

$$V(\mathbf{x}^*) = k - \mathbf{k}^T (\mathbf{K} + \sigma^2 \mathbf{I})^{-1} \mathbf{k}$$

➔ Ragam prediksi

(Rasmussen dan Williams 2006)



## Prior dan Posterior

$$P(\mathbf{f}|\mathbf{X}) = \mathcal{N}(\mathbf{f}|\boldsymbol{\mu}, \mathbf{K})$$

*Input*

$$\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3, \mathbf{x}_4, \mathbf{x}_5]$$

*Respon pada input ke-n*

$$\mathbf{f} = [f(\mathbf{x}_1), f(\mathbf{x}_2), f(\mathbf{x}_3), f(\mathbf{x}_4), f(\mathbf{x}_5)]$$


**Matriks kovarians**

$$\mathbf{K}_{ij} = k(\mathbf{x}_i, \mathbf{x}_j) = cov(\mathbf{x}_i, \mathbf{x}_j)$$

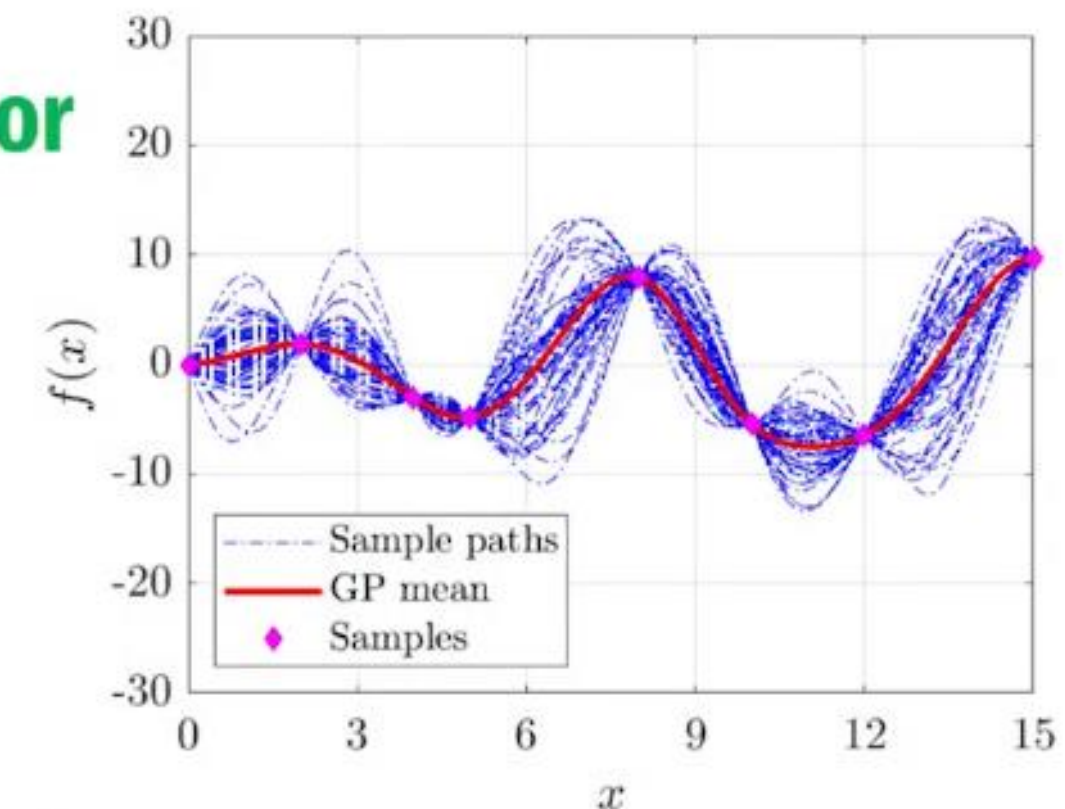
**Vektor mean**

$$\boldsymbol{\mu} = [m(\mathbf{x}_1), m(\mathbf{x}_2), m(\mathbf{x}_3), m(\mathbf{x}_4), m(\mathbf{x}_5)]$$

Prior




Posterior



## Fungsi kernel

Fungsi kernel memodelkan korelasi antara vektor acak tak terbatas



Kernel dapat membangun korelasi antara vektor acak manapun

$$\text{cov}(\mathbf{x}_i, \mathbf{x}_j) = \underbrace{\sigma_f^2}_{\text{Ragam Sinyal}} \exp \left( \frac{(\mathbf{x}_i - \mathbf{x}_j)^T (\mathbf{x}_i - \mathbf{x}_j)}{2 \underbrace{\sigma_l^2}_{\text{Panjang Skala}}} \right) + \underbrace{\sigma_l}_{\text{Noise}} I$$

Nilai-nilai ini disebut *hyperparameter* dan harus diinisiasi diawal dan dioptimalkan

## Kernel yang Digunakan Dalam Penelitian

1. Eksponensial  $cov(\mathbf{x}_i, \mathbf{x}_j) = \sigma_f^2 \exp\left(\frac{\sqrt{(\mathbf{x}_i - \mathbf{x}_j)^T (\mathbf{x}_i - \mathbf{x}_j)}}{\sigma_l}\right)$

2. Eksponensial kuadrat  $cov(\mathbf{x}_i, \mathbf{x}_j) = \sigma_f^2 \exp\left(\frac{(\mathbf{x}_i - \mathbf{x}_j)^T (\mathbf{x}_i - \mathbf{x}_j)}{2\sigma_l^2}\right)$

3. Matern 3/2

$$cov(\mathbf{x}_i, \mathbf{x}_j) = \sigma_f^2 \left(1 + \frac{\sqrt{3} \sqrt{(\mathbf{x}_i - \mathbf{x}_j)^T (\mathbf{x}_i - \mathbf{x}_j)}}{\sigma_l}\right) \exp\left(-\frac{\sqrt{3} \sqrt{(\mathbf{x}_i - \mathbf{x}_j)^T (\mathbf{x}_i - \mathbf{x}_j)}}{\sigma_l}\right)$$

(Rasmussen dan Williams 2006)



## Kernel ARD (*Automatic Relevance Determination*)

1. ARD Eksponensial  $cov(\mathbf{x}_i, \mathbf{x}_j) = \sigma_f^2 \exp \left( - \sqrt{\sum_{m=1}^d \frac{(\mathbf{x}_{im} - \mathbf{x}_{jm})^2}{\sigma_{lm}^2}} \right)$

2. ARD Eksponensial kuadrat  $cov(\mathbf{x}_i, \mathbf{x}_j) = \sigma_f^2 \exp \left( - \frac{1}{2} \sum_{m=1}^d \frac{(\mathbf{x}_{im} - \mathbf{x}_{jm})^2}{\sigma_{lm}^2} \right)$

3. ARD Matern 3/2

$$cov(\mathbf{x}_i, \mathbf{x}_j) = \sigma_f^2 \left( 1 + \sqrt{3} \sqrt{\sum_{m=1}^d \frac{(\mathbf{x}_{im} - \mathbf{x}_{jm})^2}{\sigma_{lm}^2}} \right) \exp \left( - \sqrt{3} \sqrt{\sum_{m=1}^d \frac{(\mathbf{x}_{im} - \mathbf{x}_{jm})^2}{\sigma_{lm}^2}} \right)$$

(Rasmussen dan Williams 2006)

## OPTIMASI HYPERPARAMETER

1. Metode *maximum marginal likelihood*

- Memaksimalkan nilai marginal likelihood untuk mendapatkan nilai *hyperparameter* terbaik.
- Formula dari marginal likelihood adalah sebagai berikut:

$$\log p(y|X, \theta) = -\frac{1}{2}y^T K_y^{-1}y - \frac{1}{2}\log|K_y| - \frac{n}{2}\log 2\pi$$

$K_y = K(X, X) + \sigma_n^2 I$  adalah matriks kovarians.

(Rasmussen dan Williams 2006)

## 2. Bayesian optimization

- Mengandalkan *surrogate function* untuk menemukan nilai terbaik (Ye 2020).
- Membangun pendekatan regresi proses Gaussian dari fungsi objektif yang digunakan sebagai pengganti *surrogate function*.
- *Acquisition function expected improvement* digunakan untuk mengevaluasi probabilitas dari fungsi objektif (Ye 2020).


$$EI_{y^*}(x) = \int_{-\infty}^{\infty} \max(y^* - y, 0) p(y | x) dy$$

$x$  adalah *hyperparameter*,  $y^*$  adalah nilai fungsi objektif yang diamati,  $y$  adalah nilai baru, dan  $p(y | x)$  adalah model pengganti yaitu  $y$  sebagai skor fungsi tujuan sebenarnya.

(Rasmussen dan Williams 2006)


## 3. Grid search

- *Grid search* bekerja dengan mencoba semua kombinasi dari *hyperparameter*



## 4. Random search

- Metode ini mencoba setiap kombinasi *hyperparameter* secara acak.



## Evaluasi Model

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

$$R\text{-squared} = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y}_i)^2}$$

Keterangan :



$y_i$  = nilai aktual ke- $i$ ,

$\hat{y}_i$  = nilai prediksi ke- $i$ ,


$\bar{y}_i$  = nilai rata-rata dari data aktual.



(Cappelli et al, 2023).






# HASIL DAN PEMBAHASAN






# KONSTRUKSI MODEL AWAL



## Pelatihan Model Awal

**Konstruksi model regresi menjadi regresi proses Gaussian**

$$y_i = f(\mathbf{x}_i) + \varepsilon_i$$



$$y_i = f(\mathbf{x}_{1i}) + f(\mathbf{x}_{2i}) + f(\mathbf{x}_{3i}) + f(\mathbf{x}_{4i}) + f(\mathbf{x}_{5i}) + \varepsilon_i$$

Keterangan :

$y_i$  = Peubah respon (*hotspot*) data ke- $i$ ,

$\mathbf{x}_{1i}$  = Peubah 1 (curah hujan) data ke- $i$ ,

$\mathbf{x}_{2i}$  = Peubah 2 (anomali curah hujan) data ke- $i$ ,

$\mathbf{x}_{3i}$  = Peubah 3 (hari tanpa hujan) data ke- $i$ ,


$\mathbf{x}_{4i}$  = Peubah 4 (Indeks ENSO) data ke- $i$ ,

$\mathbf{x}_{5i}$  = Peubah 5 (Indeks IOD) data ke- $i$ ,

$\varepsilon_i$  = *Error* pada data ke- $i$ .

## Pelatihan Model Awal

- Fungsi kernel → Eksponensial kuadrat
- Metode optimisasi → *Maximum Marginal Likelihood*
- Metrik akurasi → RMSE, MAE, dan *R-squared*



**Gambar 1.** Hasil prediksi jumlah *hotspot* dari model awal regresi proses Gaussian

**Tabel 2.** Akurasi model awal regresi proses Gaussian

Jenis Data	Metrik Akurasi		
	RMSE	MAE	R-squared
Data <i>Training</i>	492,06	247,69	90,38%
Data <i>Testing</i>	1116,9	503,99	20,44%





**Model regresi proses Gaussian mengalami *overfitting*.**




***Overfitting*** kemungkinan terjadi karena kernel tidak cocok mendeskripsikan data.







# PEMILIHAN FUNGSI KERNEL




**Tabel 3.** Perbandingan nilai metrik akurasi kernel dengan model awal

Jenis Data	Fungsi Kernel	Metrik Akurasi		
		RMSE	MAE	R-squared
Data <i>Training</i>	Ekspensial kuadrat	492,06	247,69	90,38%
	<b>ARD ekspensial kuadrat</b>	501,29	245,21	90,025%
	Matern32	402,48	193,2	93,57%
	ARD Matern32	144,1	76,899	99,176%
Data <i>Testing</i>	Ekspensial kuadrat	1116,9	503,99	20,44%
	<b>ARD ekspensial kuadrat</b>	971,27	385,23	39,84%
	Matern32	1133,5	482,91	18,07%
	ARD Matern32	1227,3	473,45	3,9441%

 **ARD ekspensial kuadrat** dipilih karena menghasilkan akurasi terbaik pada *testing*.



# INISIASI NILAI AWAL PARAMETER



Inisiasi nilai awal parameter → Model Menjadi lebih akurat

$$\text{cov}(\mathbf{x}_i, \mathbf{x}_j) = \boxed{\sigma_f^2} \exp \left( -\frac{1}{2} \sum_{m=1}^d \frac{(\mathbf{x}_{im} - \mathbf{x}_{jm})^2}{\boxed{\sigma_{lm}^2}} \right) + \boxed{\sigma} I$$

**Ragam Sinyal**                      **Panjang Skala**                      **Noise**

- 💡 Digunakan nilai awal panjang skala sebesar 10.
- 💡 Nilai awal ragam sinyal dan ragam *error* sebesar standar deviasi yang diperoleh dari data *training*.

**Tabel 4.** Akurasi model awal regresi proses Gaussian tanpa nilai awal

Jenis Data	Metrik Akurasi		
	RMSE	MAE	R-squared
Data <i>Training</i>	501,29	245,21	90,025%
Data <i>Testing</i>	971,27	385,23	39,84%

**Tabel 5.** Akurasi model awal regresi proses Gaussian dengan nilai awal

Jenis Data	Metrik Akurasi		
	RMSE	MAE	R-squared
Data <i>Training</i>	656,31	301,8	82,902%
Data <i>Testing</i>	<b>865,63</b>	<b>354,63</b>	<b>52,214%</b>




## Evaluasi Model dengan Nilai Awal



**Model mampu memprediksi serta menjelaskan keragaman yang ada.**

**Nilai metrik akurasi pada data *testing* menunjukkan terjadinya peningkatan akurasi model.**


**Memberikan nilai awal yang  
mendekati solusi optimal**



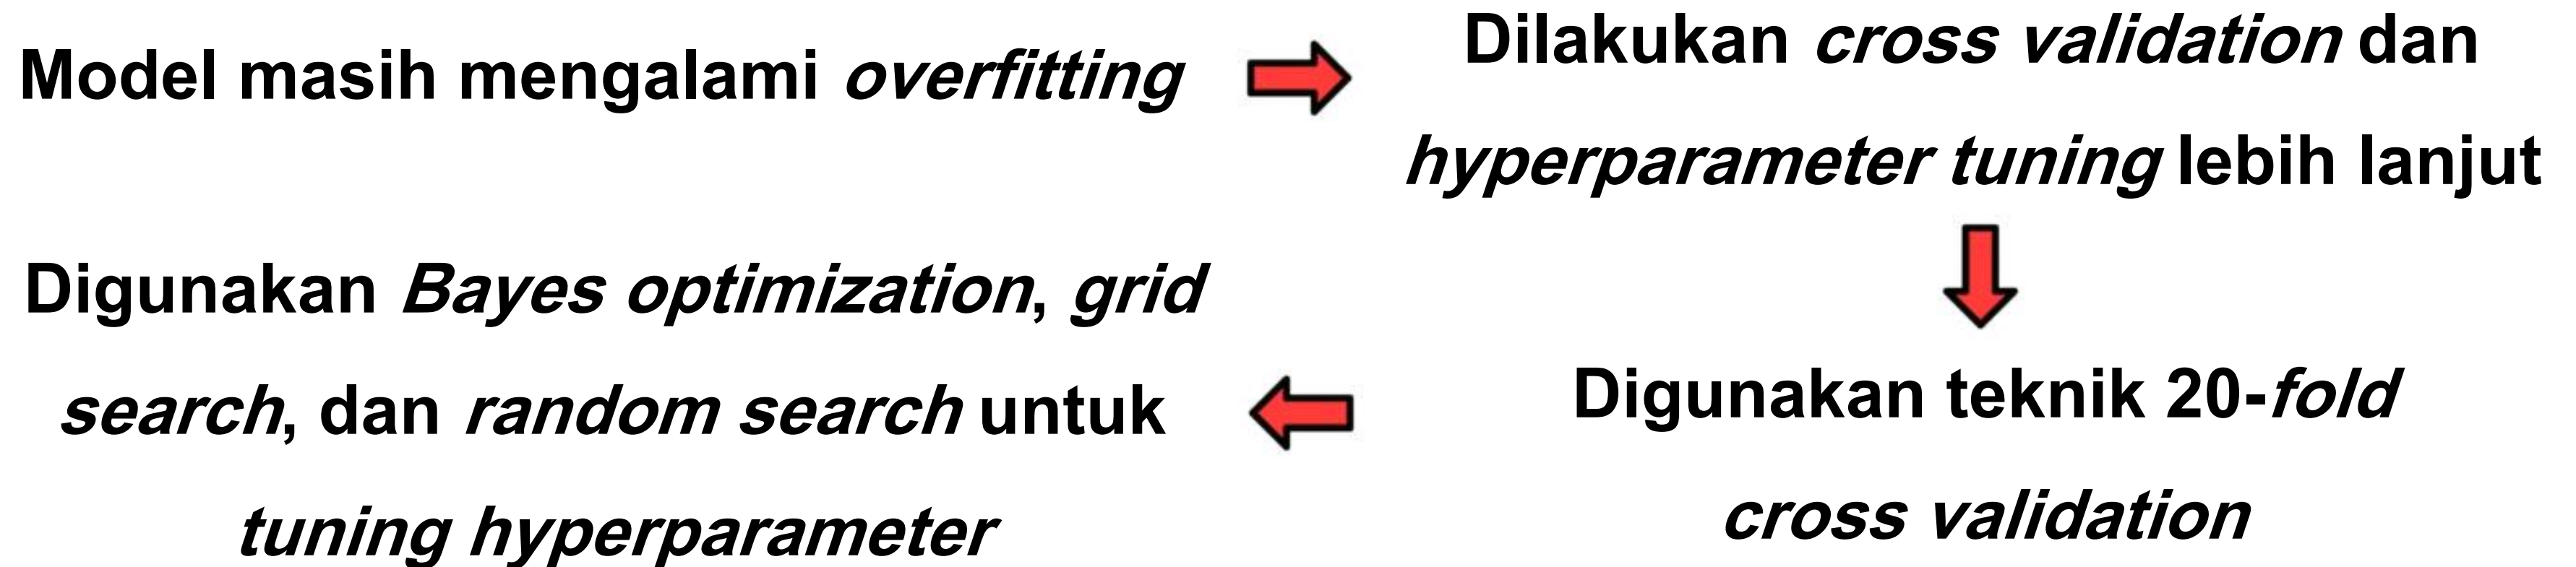
**Mempercepat algoritma dan  
mengurangi jumlah iterasi**



# KONSTRUKSI MODEL LANJUTAN



## Konstruksi Model Lanjutan




**Catatan:** Teknik ini digunakan agar data dapat dikelompokkan menjadi satu tahun sehingga terdapat 20 partisi data tahunan.  
*Hyperparameter* yang dioptimisasi adalah nilai dari *noise* ( $\sigma^2$ ).


**Tabel 6.** Komparasi nilai *measurement* dari ketiga metode optimisasi

Metode	<i>noise</i> ( $\sigma^2$ )	Metrik Akurasi		
		RMSE	MAE	R-squared
<i>Bayes optimization</i>	1274.1	713.74	320.53	78.29%
<i>Grid search</i>	1603.7	722.89	320.55	77.73%
<i>Random search</i>	1418.8	713.82	320.51	78.28%

***Bayesian optimization*  
dan *random search***





**Mampu menghasilkan performa terbaik  
dari model regresi proses Gaussian.**




**Gambar 2.** Perbandingan nilai RMSE ketiga metode optimisasi







# SIMPULAN DAN SARAN




- Fungsi kernel yang paling cocok untuk memprediksi *hotspot* berdasarkan data iklim temporal adalah **ARD eksponensial kuadrat**.
- Model regresi proses Gaussian hanya memerlukan satu ***hyperparameter*** yang dioptimisasi yaitu *noise* untuk menghasilkan akurasi terbaik.
- Model dengan performa model terbaik untuk memprediksi *hotspot* berdasarkan data iklim temporal adalah model yang dioptimalkan menggunakan ***Bayesian optimization*** dan ***random search***.

- Penggunaan data indikator iklim dapat dipisahkan berdasarkan wilayah di Kalimantan agar bisa lebih memahami hubungan antara posisi geografis dan prevalensi *hotspot*.
- Penelitian selanjutnya diharapkan dapat mengeksplorasi dan mengkombinasikan fungsi kernel lainnya.
- Metode prediksi lanjutan dari regresi proses Gaussian yaitu *deep Gaussian processes* dapat digunakan untuk melakukan prediksi pada jumlah *hotspot* di Kalimantan.



# DAFTAR PUSTAKA



- Anggraini N, Trisakti B. 2011. Kajian dampak perubahan iklim terhadap kebakaran hutan dan deforestasi di provinsi Kalimantan Barat. *Jurnal Penginderaan Jauh*. 8:11-20.
- Bramawanto R, Abida RF. 2017. Tinjauan aspek klimatologi (ENSO dan IOD) terhadap produksi garam Indonesia. *Jurnal Kelautan Nasional*. 12(1): 91-99.
- [BPS] Badan Pusat Statistik Kalimantan Timur. 2019. Analisis Pembangunan Ekonomi Regional Kalimantan Melalui Penguatan Pusat Pertumbuhan Wilayah. Kalimantan Timur(ID): BPS Kalimantan Timur.
- Cahyono SA, P Warsito S, Andayani W, H Darwanto D. 2015. Faktor-faktor yang mempengaruhi kebakaran hutan di Indonesia dan implikasi kebijakannya. *Jurnal Sylva Lestari*. 3(1):103-112.
- Ebden M. 2008. Gaussian Process : A Quick Introduction. doi: 10.48550/arXiv.1505.02965.
- Endrawati. 2016. Analisis Data Titik Panas (Hotspot) dan Areal Kebakaran Hutan dan Lahan Tahun 2016. Jakarta (ID): Direktorat Inventarisasi Daya Hutan, Ditjen Planologi Kehutanan dan Tata Lingkungan Kementerian Lingkungan Hidup dan Kehutanan.
- Fitria W, Pratama MS. 2013. Pengaruh Fenomena El Nino 1997 dan La Niña 1999 Terhadap Curah Hujan di Biak. *Jurnal Meteorologi dan Geofisika*, 14(2): 65-74.
- Isabona J, Imoize AL, Ojo S, Do DT, Lee CC. 2023. Machine Learning-Based GPR with LBFGS Kernel Parameters Selection for Optimal Throughput Mining in 5G Wireless Networks. *Sustainability* 2023, 15:1678. [Menggunakan data spatio-temporal Menggunakan metode optimisasi lain yang dapat mempersingkat waktu komputasi](#)



- Kamath A, Vargas-Hernández RA, Krems RV, Carrington T Jr, Manzhos S. 2018. Neural networks vs Gaussian process regression for representing potential energy surfaces: A comparative study of fit quality and vibrational spectrum accuracy. *J Chem Phys*. 148(24):241702. doi: 10.1063/1.5003074. PMID: 29960346.
- Kertayasa IM, Sukarasa IK, Widagda IGA, Hendrawan IG. 2013. Pengaruh Indian Ocean Dipole Mode (IODM) terhadap intensitas hujan di Benua Maritim Indonesia (BMI) barat. *Buletin Fisika*. 14 (1):25-30.
- Lubbe F, Maritz J, Harms T. 2020. Evaluating the Potential of Gaussian Process Regression for Solar Radiation Forecasting: A Case Study. *Energies*. 13(20):5509. [Menggunakan data spatio-temporal Menggunakan metode optimisasi lain yang dapat mempersingkat waktu komputasi.](#)
- Ma J, Ma X. 2017. State-of-the-art forecasting algorithms for microgrids. *International Conference on Automation and Computing (ICAC)*. 23(1): 1–6. doi: 10.23919/IConAC.2017.8082049.
- Mardiani D. 2014. Hubungan curah hujan dan titik panas (hotspot) dalam kaitannya dengan terjadinya kebakaran di Provinsi Aceh [skripsi]. Bogor (ID): Institut Pertanian Bogor.
- Minku LL, Yao X. 2013. Ensembles and Locality: Insight on improving software effort estimation. *Elsevier, Information and Software Technology*. 55(8):1512-1528.
- Duvenaud D. 2014. Automatic model construction with Gaussian processes [tesis]. Cambridge(UK): University of Cambridge.
- Mukid MA. 2009. Regresi Proses Gaussian untuk Pemodelan Kalibrasi [tesis]. Bogor(ID): Institut Pertanian Bogor.

- Nabilah F, Prasetyo Y, Sukmono A. 2017. Analisis pengaruh fenomena el nino dan la nina terhadap curah hujan tahun 1998-2016 menggunakan indicator ONI (Oceanic Nino Index). Jurnal Geodesi Undip. 6(4):402-412.
- Najib MK. 2022. Analisis Multivariat dan Pemodelan Hotspot Berdasarkan Indikator Iklim di Kalimantan Menggunakan Copula [tesis]. Bogor(ID): Institut Pertanian Bogor.
- Nurdiati S, Sopaheluwakan A, Julianto MT, Septiawan P, Rohimahastuti F. 2021. Modelling and analysis impact of El Nino and IOD to land and forest fire using polynomial and generalized logistic function: cases study in South Sumatra and Kalimantan, Indonesia. Modeling Earth Systems and Environmental. 8:3341-3356. doi:10.1007/s40808-021-013034.
- Nurdiati S, Bukhari F, Najib MK, Hilmi K. 2022. Prediksi masa studi mahasiswa IPB berdasarkan indeks prestasi kumulatif menggunakan jaringan syaraf tiruan. MILANG: Journal of Mathematics and Its Application. 18(1):1-13. doi:10.29244/milang.18.1.1-13.
- Prakash AK, Xu S, Rajagopal R, Noh HY. Robust Building Energy Load Forecasting Using Physically-Based Kernel Models. Energies. 2018. 11(4):862. [Menggunakan data spatio-temporal Menggunakan metode optimisasi lain yang dapat mempersingkat waktu komputasi.](#)
- Rahayu ND, Sasmito B, Bashit N. 2018. Analisis pengaruh fenomena indian ocean dipole (IOD) terhadap curah hujan di pulau jawa. Jurnal Geodesi Undip.7(1).
- Rasmussen CE, Williams CKI. 2006. Gaussian Processes for Machine Learning. Massachusetts: MIT Press.
- Ryadi GYI, Sukmono A, Sasmito B. 2019. Pengaruh fenomena el nino dan la nina pada persebaran curah hujan dan tingkat kekeringan lahan di Pulau Bali. Jurnal Geodesi Undip. 8(4): 41-49.

- Saharjo BH, Hasanah U. 2023. Analisis Faktor Penyebab Terjadinya Kebakaran Hutan dan Lahan di Kabupaten Pulang Pisang, Kalimantan Tengah. *Jurnal Silvikultur Tropika*. 14(1):25-29.
- Sepriando A, Trisantikawaty R. 2016. Pengolahan Data Radar Cuaca Format Netcdf Menggunakan Bahasa Program Python. *Prosiding Workshop Operasional Radar Cuaca 2016*. 1(1):29-33.
- Suryanata M, Maulana K. 2023. Statistik Daerah Provinsi Kalimantan Timur 2023. Kalimantan: Badan Pusat Statistik Provinsi Kalimantan Timur.
- Syaufina L. 2008. Kebakaran Hutan dan Lahan di Indonesia. Pola, penyebab dan dampak kebakaran. Malang (ID): Bayumedia Publishing.
- Visser E, Daalen CEV, Schoeman JC. 2022. Lossy compression of observations for Gaussian process regression. *MATEC Web of Conferences*. 37(1):1-9. doi:10.1051/mateconf/202237007006.
- Willmott CJ, Matsuura K. 2005. Advantages of the Mean Absolute Error (MAE) over the Root Mean Square Error (RMSE) in Assessing Average Model Performance. *Climate Research*. 30(1):79-82. doi:10.3354/cr030079.
- Yadav A, Bareth R, Kochar M, Pazoki M, Sehiemy RAE. 2023. Gaussian process regression-based load forecasting model. *IET Generation, Transmission & Distribution*. 1-12. doi:10.1049/gtd2.12926.
- Ye W, Alawieh MB, Li M, Lin Y, Pan DZ. 2019. Litho-GPA: Gaussian Process Assurance for Lithography Hotspot Detection. 2019Design, Automation & Test in Europe Conference & Exhibition (DATE). 54-29. doi:10.23919/DATE.2019.8714960.



# TERIMA KASIH



**IPB University**  
— Bogor Indonesia —

**Departemen Matematika**  
**Jl. Meranti W22 L5**  
**Kampus IPB Dramaga Bogor 16680**  
**Telp.: 0251-8625276**  
**E-mail: [math@apps.ipb.ac.id](mailto:math@apps.ipb.ac.id)**